

ÍNDICE DE VULNERABILIDAD LABORAL EN PEREIRA

Clasificación mediante Machine Learning de la población
en situación de informalidad y desempleo

BootCamp IA 2026

Pereira, Risaralda — Colombia

Fuente de datos: Alcaldía de Pereira & Datos Abiertos

Departamento de Ciencia de Datos e Inteligencia Artificial

13,987

Personas analizadas

51.9%

Presentan vulnerabilidad Alta

98.96
%

Accuracy del mejor modelo

Comparación de modelos evaluados

Modelo	Accurac y	Precisión Vul. Baja	Precisión Vul. Alta	Falsos Neg.	Falsos Pos.
Random Forest	98.96 %	99.33 %	98.62 %	20	9
Árbol de Decisión	97.46 %	99.70 %	95.39 %	67	4
SVC	97.21 %	98.59 %	95.94 %	59	19
Regresión Logística	97.07 %	98.22 %	96.01 %	58	24

* Fila resaltada en verde = modelo seleccionado para producción (Random Forest)

Este documento presenta el proceso completo de análisis de datos y entrenamiento del modelo de Machine Learning para la clasificación del nivel de vulnerabilidad laboral de la población de Pereira. El modelo seleccionado — **Random Forest** con 300 árboles — logró un accuracy del **98.96%** y ha sido guardado en formato .pkl para su despliegue en una aplicación interactiva o chatbot de clasificación ciudadana.

1. INTRODUCCIÓN

La ciudad de Pereira, capital del departamento de Risaralda y epicentro de la región del Eje Cafetero colombiano, enfrenta una problemática estructural en materia de empleo e informalidad laboral que afecta a una proporción significativa de su población. A pesar de ser una de las ciudades intermedias con mayor dinamismo económico del país, persisten brechas importantes en las condiciones de vida de sus habitantes, particularmente en sectores vulnerables.

La informalidad laboral en Pereira se manifiesta a través de múltiples dimensiones: trabajadores por cuenta propia sin afiliación a seguridad social, empleados en actividades de comercio informal, personas en situación de desempleo estructural, y hogares con jefatura femenina que enfrentan barreras adicionales para acceder al mercado laboral formal. Según registros de la Alcaldía de Pereira, una parte considerable de la población activa opera en condiciones de informalidad, lo que limita su acceso a beneficios de seguridad social, estabilidad económica y oportunidades de movilidad social.

FACTORES DE VULNERABILIDAD IDENTIFICADOS

Los factores que inciden directamente en la condición de vulnerabilidad laboral en Pereira incluyen:

- **Condición ocupacional:** El desempleo, la búsqueda activa de empleo y el trabajo no remunerado en el hogar representan las condiciones de mayor riesgo, limitando el acceso a ingresos estables y cobertura social.
- **Nivel educativo:** La ausencia o bajo nivel de formación académica actúa como barrera estructural para acceder a empleos formales y bien remunerados. Las personas sin escolaridad o con educación básica primaria concentran los índices más altos de vulnerabilidad.
- **Tipo de afiliación en salud:** El régimen de seguridad en salud es un indicador directo de la situación económica del individuo. Las personas en régimen subsidiado o vinculadas representan la mayor concentración de vulnerabilidad social.
- **Jefatura del hogar:** Los hombres y mujeres cabeza de familia asumen cargas económicas desproporcionadas, especialmente en contextos de informalidad, incrementando su nivel de riesgo.
- **Condición de discapacidad:** Las personas en condición de discapacidad enfrentan barreras adicionales para la inclusión laboral, amplificando su vulnerabilidad.
- **Adulto mayor:** La población mayor de 60 años presenta dificultades para mantenerse en el mercado laboral formal, dependiendo en muchos casos de ingresos informales o apoyo familiar.

- **Zona de residencia:** La ubicación en zonas rurales o periurbanas limita el acceso a oportunidades de empleo formal, infraestructura educativa y servicios sociales.
- **Pertenencia étnica:** Las comunidades afrodescendientes e indígenas enfrentan barreras históricas de discriminación que se traducen en mayor informalidad y exclusión del mercado laboral formal.

Ante este panorama, el presente proyecto propone el desarrollo de un sistema inteligente de clasificación basado en Machine Learning que permita identificar y categorizar automáticamente el nivel de vulnerabilidad de la población pereirani, con el objetivo de orientar políticas públicas focalizadas y facilitar la implementación de una aplicación interactiva para la consulta ciudadana y la toma de decisiones institucionales.

2. OBJETIVOS

OBJETIVO GENERAL

Desarrollar un modelo de Machine Learning para la clasificación binaria del nivel de vulnerabilidad laboral (Alto / Bajo) de la población registrada en Pereira, utilizando datos sociodemográficos y ocupacionales provenientes de los registros de la Alcaldía de Pereira, con el fin de apoyar la toma de decisiones en política social y facilitar su despliegue en una aplicación interactiva de clasificación ciudadana.

OBJETIVOS ESPECÍFICOS

- Realizar un Análisis Exploratorio de Datos (EDA) exhaustivo sobre el dataset de caracterización de informalidad de Pereira, identificando distribuciones, correlaciones y patrones de vulnerabilidad en la población.
- Construir un índice cuantitativo de vulnerabilidad basado en variables sociodemográficas ponderadas según su impacto en la exclusión laboral y social, estableciendo umbrales de clasificación fundamentados en la distribución estadística de los datos.
- Preprocesar y transformar el dataset original para garantizar la calidad de los datos de entrada al modelo, incluyendo limpieza, filtrado de rangos de edad, codificación de variables categóricas y eliminación de variables con bajo poder predictivo.
- Entrenar, comparar y evaluar múltiples algoritmos de clasificación supervisada (Regresión Logística, Árbol de Decisión, Random Forest y Máquina de Vectores de Soporte) utilizando métricas de desempeño como accuracy, precisión y sensibilidad por clase.
- Seleccionar el modelo óptimo con base en su desempeño en el conjunto de prueba y persistirlo en formato pickle para su uso en producción dentro de una aplicación o chatbot interactivo.
- Identificar las variables con mayor poder predictivo sobre el nivel de vulnerabilidad, proporcionando insumos para el diseño de políticas públicas focalizadas en la población más vulnerable de Pereira.
- Documentar el proceso completo de ciencia de datos — desde la obtención de datos hasta el despliegue del modelo — generando un informe técnico de referencia para futuras implementaciones.

3. METODOLOGÍA

3.1 DETECCIÓN DEL PROBLEMA

La identificación de la problemática surgió del análisis de las condiciones socioeconómicas de la ciudad de Pereira, donde la informalidad laboral representa un desafío persistente para el desarrollo equitativo. La necesidad de contar con herramientas analíticas que permitan caracterizar objetivamente los niveles de vulnerabilidad de la población motivó el planteamiento de una solución basada en inteligencia artificial y aprendizaje automático.

3.2 OBTENCIÓN Y FUENTES DE DATOS

El conjunto de datos fue construido a partir de los **registros oficiales de la Alcaldía de Pereira** sobre caracterización de la informalidad laboral, complementados con información de páginas y fuentes institucionales afines a la temática de empleo, pobreza y vulnerabilidad social en el municipio. Para optimizar la búsqueda y selección de los registros más representativos, se emplearon herramientas de **inteligencia artificial exploratoria**, que permitieron identificar y consolidar los datos con mayor precisión y pertinencia para el estudio.

- **16,670 registros** en el dataset original con 18 variables sociodemográficas.
- Período de vigencia de los datos: 2021 - 2024.
- Variables incluidas: género, edad, tipo de identificación, condición de discapacidad, jefatura del hogar, orientación sexual, experiencia migratoria, adulto mayor, grupo étnico, tipo de seguridad en salud, nivel educativo, condición ocupacional, barrio/vereda, comuna, zona de residencia y departamento de procedencia.

3.3 LIMPIEZA Y PREPARACIÓN DEL DATASET

- **Filtrado por edad:** Se conservaron únicamente registros de personas entre 16 y 85 años, rango correspondiente a la población económicamente activa y adulta mayor.
- **Eliminación de columnas:** Se removieron variables sin aporte predictivo: Tipo de Identificación, Orientación Sexual LGTBI, Departamento de Procedencia, Vigencia, Tipo de Discapacidad, Comuna/Corregimiento y Experiencia Migratoria.
- **Estandarización:** Nombres de columnas normalizados a mayúsculas con guion bajo y sin tildes en los identificadores. Valores de texto normalizados a mayúsculas.
- **Dataset final:** 13,987 registros con 14 variables limpias y procesadas.

3.4 CONSTRUCCIÓN DEL ÍNDICE DE VULNERABILIDAD

Dado que el dataset original no contaba con una variable objetivo explícita, se construyó un **índice de vulnerabilidad cuantitativo** basado en la literatura especializada en exclusión

social. El índice asigna puntajes ponderados a cada factor de riesgo:

Factor de riesgo	Condición	Puntos
Condición Ocupacional	Desempleado / Buscando Empleo	+3
Condición Ocupacional	Ama de Casa / Ninguno	+2
Seguridad en Salud	Población Vinculada	+3
Seguridad en Salud	Régimen Subsidiado	+2
Jefatura del Hogar	Cabeza de Familia (Sí)	+2
Nivel Educativo	Sin educación formal	+3
Nivel Educativo	Preescolar / Básica Primaria	+2
Discapacidad	Sí presenta discapacidad	+2
Adulto Mayor	Mayor de 60 años	+1
Zona de Residencia	Zona Rural	+1
Grupo Étnico	Comunidad Afro / Indígena	+1

Clasificación final: Puntaje $\leq 2 \rightarrow$ Vulnerabilidad Baja | Puntaje $> 2 \rightarrow$ Vulnerabilidad Alta. El umbral de 2 puntos fue seleccionado por ser el punto más cercano al balance 50/50 entre clases según el análisis de distintos umbrales en el EDA.

4. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

4.1 VISIÓN GENERAL DEL DATASET

El análisis exploratorio se realizó sobre el dataset depurado de 13,987 personas con edades entre 16 y 85 años. A continuación se presenta la distribución del índice de vulnerabilidad y del puntaje asignado, que fundamentan la variable objetivo del modelo.




Figura 1: Distribución y proporción del Nivel de Vulnerabilidad en la población analizada.

El **51.9% de la población analizada presenta vulnerabilidad Alta** (7,260 personas) y el 48.1% vulnerabilidad Baja (6,727 personas). Esta distribución relativamente balanceada entre clases favorece el entrenamiento de modelos de clasificación binaria sin necesidad de técnicas de sobremuestreo o submuestreo, garantizando que el modelo aprenda por igual a identificar ambos grupos.




Figura 2: Distribución del Puntaje de Vulnerabilidad (0-13). La línea punteada indica el umbral de clasificación en 2.

El puntaje de vulnerabilidad presenta una distribución con media de **2.90**, desviación estándar de 2.42, mínimo de 0 y máximo de 13. La mayoría de personas se concentra en puntajes entre 0 y 5, con una caída pronunciada en puntajes mayores, lo que indica que los casos de vulnerabilidad extrema son poco frecuentes pero de especial atención para la política pública.

Análisis: La construcción del índice logra segmentar de manera clara la población. La acumulación de casos en puntajes bajos (0-2) refleja que una parte significativa de la población registrada cuenta con condiciones laborales y sociales aceptables; sin embargo, el volumen de personas con puntaje 3-6 indica que la vulnerabilidad moderada es el estado más común en la ciudad, lo que debe orientar programas preventivos y no solo de atención a casos extremos.

4.2 VULNERABILIDAD POR GÉNERO




Figura 3: Vulnerabilidad por género — valores absolutos (izq.) y distribución porcentual (der.).

La población femenina (8,800 mujeres) supera ampliamente a la masculina (5,181 hombres) en el dataset, reflejo de la mayor participación de mujeres en los registros de caracterización social de la Alcaldía. En términos de vulnerabilidad, **las mujeres concentran una proporción mayor de casos en la categoría Alta**, impulsado principalmente por la condición de ama de casa y jefatura del hogar — factores a los que el índice asigna las mayores ponderaciones. Los hombres presentan una distribución más equilibrada, asociada a su mayor participación en el empleo formal e independiente.

Análisis: La brecha de género en vulnerabilidad laboral evidencia una problemática estructural: las mujeres asumen con mayor frecuencia roles de cuidado no remunerado y jefatura de hogar que las excluyen del mercado formal. Las intervenciones de política pública deben priorizar programas de empleabilidad femenina, guarderías y apoyo a madres cabeza de familia para reducir esta brecha.

4.3 VULNERABILIDAD POR CONDICIÓN OCUPACIONAL




Figura 4: Distribución porcentual del nivel de vulnerabilidad por condición ocupacional.

La condición ocupacional emerge como el **predictor más potente de vulnerabilidad** (correlación: -0.431). Se identifican dos grupos claramente diferenciados: personas desempleadas y buscando empleo concentran prácticamente el 100% de sus casos en la categoría Alta, mientras que empleados formales y estudiantes dominan la categoría Baja. Los trabajadores independientes presentan una distribución mixta, reflejando la heterogeneidad de este grupo — que incluye desde vendedores informales hasta profesionales autónomos con ingresos estables.

Análisis: El empleo formal actúa como el principal factor protector de vulnerabilidad. Las personas en búsqueda de empleo y desempleados requieren atención prioritaria e inmediata, ya que combinan la ausencia de ingresos con la falta de cobertura en seguridad social. Los programas de intermediación laboral y formación para el trabajo son las intervenciones más directas para este grupo.

4.4 VULNERABILIDAD POR RANGO DE EDAD




Figura 5: Vulnerabilidad por rango de edad — valores absolutos (izq.) y distribución porcentual (der.).

El rango 16-25 años concentra el mayor número absoluto de personas registradas (4,145 individuos), mientras que en términos porcentuales la vulnerabilidad Alta crece progresivamente con la edad. Los grupos de adultos mayores (56-65 y 66-85) presentan las proporciones más altas de vulnerabilidad, consistente con las dificultades de reinserción laboral en edades avanzadas y el mayor peso del factor "adulto mayor" en el índice construido.

Análisis: El alto volumen de jóvenes de 16-25 años en el registro refleja una población económicamente activa en transición hacia el mercado laboral, con niveles mixtos de vulnerabilidad. La atención diferenciada por ciclo de vida es clave: mientras los jóvenes requieren programas de primer empleo y formación técnica, los adultos mayores necesitan esquemas de protección social y económica adaptados a su etapa de vida.

4.5 VULNERABILIDAD POR NIVEL EDUCATIVO




Figura 6: Distribución porcentual del nivel de vulnerabilidad por nivel educativo.

Se observa una relación clara e inversa entre nivel educativo y vulnerabilidad: **a mayor educación, menor vulnerabilidad**. Las personas con preescolar o básica primaria alcanzan proporciones cercanas al 100% de vulnerabilidad Alta, mientras que a partir del nivel profesional la vulnerabilidad alta es prácticamente inexistente. La educación técnica y tecnológica muestra niveles intermedios, posicionándose como una vía de acceso al empleo formal que reduce significativamente el riesgo.

Análisis: La educación es el factor protector de mayor alcance a largo plazo. Cada nivel educativo adicional reduce sustancialmente la probabilidad de caer en vulnerabilidad Alta. Los programas de alfabetización, bachillerato flexible para adultos y subsidios para educación técnica son las herramientas más efectivas para romper el ciclo de vulnerabilidad intergeneracional.

4.6 VULNERABILIDAD POR TIPO DE SEGURIDAD EN SALUD




Figura 7: Distribución porcentual del nivel de vulnerabilidad por régimen de salud.

El tipo de afiliación en salud es el **segundo predictor más importante** (correlación: 0.336) del modelo. Las personas con régimen contributivo presentan mayoritariamente vulnerabilidad Baja, indicando estabilidad laboral y capacidad de aporte. En contraste, el régimen subsidiado y la población vinculada concentran la gran mayoría de los casos de vulnerabilidad Alta, siendo indicadores directos de precariedad económica e informalidad laboral.

Análisis: El régimen de salud funciona como un proxy confiable de la situación económica. La transición del régimen subsidiado al contributivo — que implica formalización laboral — es uno de los indicadores más directos de mejora en las condiciones de vida. Las políticas de formalización del empleo impactarán directamente en el tipo de cobertura en salud y, consecuentemente, en el nivel de vulnerabilidad medido.

4.7 DISTRIBUCIÓN GEOGRÁFICA — TOP 10 BARRIOS CON MAYOR VULNERABILIDAD




Figura 8: Top 10 barrios de Pereira con mayor concentración de población en vulnerabilidad Alta.

El análisis geográfico identifica los territorios con mayor concentración de población en vulnerabilidad Alta, coincidiendo con zonas históricamente marginadas de la ciudad: Las Brisas, Remanso, Villa Santana, Salamanca y Tokio, entre otros. Estos barrios presentan condiciones estructurales de precariedad — informalidad habitacional, limitado acceso a servicios y alejamiento de los centros de empleo formal — que se retroalimentan con la vulnerabilidad laboral.

Análisis: La concentración geográfica de la vulnerabilidad permite focalizar territorialmente las intervenciones. La aplicación interactiva de clasificación deberá incorporar esta dimensión espacial para priorizar la atención institucional en las comunas y barrios con mayor densidad de personas en riesgo Alto, optimizando el uso de los recursos públicos disponibles.

4.8 ANÁLISIS DE CORRELACIÓN ENTRE VARIABLES




Figura 9: Coeficiente de correlación de cada variable con el Puntaje de Vulnerabilidad.

El análisis de correlación confirma la jerarquía de factores predictivos y orienta la construcción del modelo. Las variables con mayor correlación con el puntaje de vulnerabilidad son:

Variable	Correlación	Interpretación
CONDICION_OCUPACIONAL	−0.431	Empleo formal → reduce vulnerabilidad
GRUPOS_ETNICOS	−0.374	Codificación: mestizo tiene valor alto
TIPO_DE_SEGURIDAD_SALUD	+0.336	Subsidiado / Vinculado → mayor riesgo
ADULTO_MAYOR	+0.316	Ser adulto mayor incrementa el riesgo
EDAD	+0.292	Mayor edad correlaciona con riesgo
DISCAPACIDAD	+0.264	Discapacidad como factor agravante
JEFATURA DEL HOGAR	+0.183	Carga adicional para el hogar
NIVEL_EDUCATIVO	−0.150	Mayor educación → menor vulnerabilidad

Análisis: La condición ocupacional, el grupo étnico y el tipo de seguridad en salud son los tres factores con mayor poder discriminatorio, aportando más del 60% de la señal predictiva del modelo. La variable de experiencia migratoria no mostró correlación relevante (≈ 0.000) y fue eliminada antes del entrenamiento, reduciendo la dimensionalidad sin afectar el desempeño.

5. APLICACIÓN DEL MODELO DE MACHINE LEARNING

5.1 VARIABLES DEL MODELO Y PREPROCESAMIENTO

El modelo de clasificación recibe como entrada las variables del dataset depurado. El preprocesamiento se implementa dentro de un Pipeline de scikit-learn que garantiza la transformación automática de los datos en producción:

Variable	Tipo	Transformación
NIVEL_EDUCATIVO_QUE_TIENE_O_CURSA	Ordinal	OrdinalEncoder
EDAD	Numérica	Passthrough
GENERO	Nominal	OneHotEncoder
PERSONAS_EN_CONDICION_DISCAPACIDAD	Nominal	OneHotEncoder
HOMBRES_MUJERES_CABEZA_FAMILIA	Nominal	OneHotEncoder
ADULTO_MAYOR	Nominal	OneHotEncoder
GRUPOS_ETNICOS_AFRO_INDIGENA	Nominal	OneHotEncoder
TIPO_DE_SEGURIDAD_EN_SALUD	Nominal	OneHotEncoder
CONDICION_OCUPACIONAL	Nominal	OneHotEncoder
BARRIO_O_VEREDA_DE_RESIDENCIA	Nominal	OneHotEncoder
ZONA_DE_RESIDENCIA	Nominal	OneHotEncoder
RANGO_EDAD	Nominal	OneHotEncoder

El dataset fue dividido en conjuntos de **entrenamiento (80%) y prueba (20%)** con muestreo estratificado para garantizar la representación proporcional de ambas clases. Esto resultó en aproximadamente **11,190 registros de entrenamiento** y **2,798 de prueba**, con random_state=42 para garantizar reproducibilidad.

5.2 ALGORITMOS EVALUADOS

- **Regresión Logística:** Clasificador lineal con regularización C=0.05 y max_iter=5,000. Modelo base de alta interpretabilidad.
- **Árbol de Decisión:** Clasificador no lineal con max_depth=7 y min_samples_leaf=2. Alta interpretabilidad visual y buena velocidad de inferencia.
- **Random Forest:** Ensemble de 300 árboles con bootstrap. Mayor robustez y resistencia al sobreajuste gracias a la agregación de predicciones.

- **SVC (Support Vector Classifier):** Kernel RBF con $C=10$ y $\gamma=0.001$. Eficaz en espacios de alta dimensionalidad generados por el OneHotEncoder.

6. RESULTADOS Y MEDICIÓN DEL DESEMPEÑO

6.1 COMPARACIÓN DE ACCURACY ENTRE MODELOS




Figura 10: Accuracy de los cuatro modelos evaluados en el conjunto de prueba.

Los cuatro modelos evaluados superaron el 97% de accuracy en el conjunto de prueba, evidenciando que las variables seleccionadas poseen un elevado poder discriminatorio. El **Random Forest** alcanzó el mejor desempeño con **98.96%**, seguido del Árbol de Decisión (97.46%), SVC (97.21%) y Regresión Logística (97.07%).

Modelo	Accurac y	Precisión Vul. Baja	Precisión Vul. Alta	Falsos Negativos	Falsos Positivos
Random Forest	98.96 %	99.33 %	98.62 %	20	9
Árbol de Decisión	97.46 %	99.70 %	95.39 %	67	4
SVC	97.21 %	98.59 %	95.94 %	59	19
Reg. Logística	97.07 %	98.22 %	96.01 %	58	24

* Fila resaltada en verde = modelo seleccionado para producción.

Análisis: Aunque el Árbol de Decisión presenta la mayor precisión en vulnerabilidad Baja (99.70%), el Random Forest es superior en el balance global: minimiza los falsos negativos (20 vs 67) — el error más crítico en este contexto, ya que clasificar a una persona vulnerable como no vulnerable puede significar la exclusión de programas sociales que necesita. Por esta razón, el Random Forest fue seleccionado como el modelo de producción.

6.2 MATRIZ DE CONFUSIÓN — RANDOM FOREST




Figura 11: Matriz de confusión del Random Forest sobre el conjunto de prueba (2,798 registros).

La matriz de confusión del modelo seleccionado evidencia su alto desempeño en ambas clases de manera simultánea:

- **1,337 personas** correctamente clasificadas como Vulnerabilidad Baja (99.33% de precisión).
- **1,432 personas** correctamente clasificadas como Vulnerabilidad Alta (98.62% de precisión).
- **Solo 9 casos** de Vulnerabilidad Baja clasificados como Alta (falsos positivos).
- **Solo 20 casos** de Vulnerabilidad Alta clasificados como Baja (falsos negativos) — el error de mayor impacto en política social.

El modelo fue guardado en formato **.pkl** mediante la librería joblib, empaquetado junto con los metadatos necesarios para producción: columnas de entrada, mediana del puntaje de vulnerabilidad, mapeo de clases y criterio de clasificación. Este paquete está listo para integrarse directamente en una aplicación web o chatbot interactivo.

7. CONCLUSIONES

7.1 CONCLUSIONES DEL ANÁLISIS EXPLORATORIO (EDA)

Los análisis exploratorios realizados permitieron comprender en profundidad la estructura y las dinámicas de vulnerabilidad en la población registrada de Pereira, respondiendo al objetivo de identificar distribuciones, correlaciones y patrones clave. Las principales conclusiones del EDA son:

- El dataset de 13,987 personas registra una distribución equilibrada entre niveles de vulnerabilidad (52% Alta / 48% Baja), lo que constituye una condición óptima para el entrenamiento de modelos de clasificación binaria sin técnicas adicionales de balanceo de clases.
- La **condición ocupacional** resulta ser el factor determinante de vulnerabilidad, con el desempleo y la búsqueda activa de empleo como los estados de mayor riesgo. El empleo formal actúa como el principal factor protector dentro de la población analizada.
- El **nivel educativo** mantiene una relación inversamente proporcional con la vulnerabilidad: la población sin educación formal o con básica primaria concentra los índices más altos de riesgo, mientras que a partir del nivel profesional la vulnerabilidad alta es prácticamente inexistente.
- El **tipo de régimen de salud** funciona como proxy confiable del nivel económico: el régimen subsidiado y la población vinculada concentran la gran mayoría de los casos de vulnerabilidad Alta, constituyendo el segundo predictor más importante del índice construido.
- Las **mujeres** presentan mayor proporción de vulnerabilidad Alta en comparación con los hombres, principalmente por su mayor participación en roles de ama de casa y jefatura del hogar sin ingreso formal, evidenciando una brecha de género estructural.
- Geográficamente, los barrios **Las Brisas, Remanso, Villa Santana, Salamanca y Tokio** concentran la mayor cantidad de población en vulnerabilidad Alta y se convierten en focos prioritarios de intervención social y territorial.
- La variable de experiencia migratoria no aporta poder predictivo (correlación ≈ 0.000) y fue eliminada antes del entrenamiento, confirmando que la simplificación del modelo no implica pérdida de información relevante.

7.2 CONCLUSIONES DEL MODELO DE MACHINE LEARNING

El proceso de entrenamiento, evaluación y selección del modelo responde directamente a los objetivos planteados en el proyecto. Las principales conclusiones son:

- Se entrena, compara y evalúa exitosamente cuatro algoritmos de clasificación supervisada. El **Random Forest con 300 árboles** es seleccionado como el modelo óptimo, alcanzando un **accuracy del 98.96%** en el conjunto de prueba — el desempeño

más alto entre todos los candidatos evaluados.

- Los cuatro modelos superan el 97% de accuracy, lo que confirma que las variables seleccionadas poseen un poder discriminatorio muy alto y que el índice de vulnerabilidad construido es estadísticamente robusto y bien definido como variable objetivo.
- El Random Forest minimiza los **falsos negativos** (20 casos frente a 67 del Árbol de Decisión), lo cual es crítico en el contexto de política social: clasificar erróneamente a una persona vulnerable como no vulnerable tiene consecuencias más graves que el error inverso.
- Se implementa un Pipeline de scikit-learn que integra preprocesamiento y clasificación, garantizando que el modelo pueda recibir datos en formato crudo en producción sin transformaciones manuales adicionales, facilitando su despliegue en aplicaciones reales.
- El modelo es persistido en formato **.pkl** mediante joblib, empaquetado con todos sus metadatos necesarios (columnas de entrada, mapeo de clases, criterio de clasificación), quedando listo para integrarse directamente en el chatbot o aplicación interactiva de clasificación ciudadana.
- Las variables de **condición ocupacional, tipo de seguridad en salud y nivel educativo** son identificadas como los factores más determinantes del modelo, proporcionando insumos concretos para el diseño de políticas públicas focalizadas y para estructurar las preguntas del chatbot de manera que maximicen la precisión de la clasificación con la menor fricción para el usuario.
- El proyecto establece las bases técnicas y metodológicas para un sistema de alerta temprana que permita a la Alcaldía de Pereira identificar proactivamente población en riesgo y focalizar programas de empleo, formación y asistencia social de manera más eficiente y equitativa.

Nota de despliegue: Este informe técnico sirve como referencia para la integración del modelo en una aplicación web o chatbot interactivo de clasificación. El sistema permitirá a ciudadanos y funcionarios ingresar datos sociodemográficos y obtener en tiempo real la clasificación de su nivel de vulnerabilidad laboral, apoyando la toma de decisiones en política social en la ciudad de Pereira.